

Universidad Tecnológica de Tula-Tepeji.
Carrera: Ingeniería en Desarrollo y Gestión de Software

Proyecto: Predicción de la calidad del vino mediante características fisicoquímicas

Materia: Extracción de Conocimiento en Bases de Datos

Unidad: I. Introducción al análisis de datos — Recursamiento 2026

Actividad de Evaluación — Unidad I. Planeación del Proyecto de Análisis de Datos

Valor: 20 puntos (20%)

Alumno:


Alberto Yael Zongua Hernández

Modalidad: Individual

Grupo: 10 IDGS-G1

Docente: Ing. José Luis Herrera Gallardo, MTI

Fecha de entrega: 2 de octubre de 2026





Nombre del proyecto

Predicción de la calidad del vino mediante características fisicoquímicas.

Descripción del proyecto

La industria vitivinícola evalúa tradicionalmente la calidad de sus productos mediante paneles de cata sensorial, en los que expertos asignan una puntuación con base en el sabor, aroma y otras percepciones subjetivas. Este método, aunque valioso, es lento, costoso y depende del criterio humano, lo que dificulta su aplicación sistemática durante el proceso de producción.

Este proyecto se desarrolla a partir del caso asignado para el recursamiento: analizar el conjunto de datos Wine Quality, que reúne pruebas fisicoquímicas de laboratorio (acidez, azúcar, alcohol, sulfatos, entre otras) realizadas sobre muestras de vino verde portugués, tanto tinto como blanco, junto con la puntuación de calidad otorgada por catadores expertos. El propósito es explorar si estas propiedades, medibles de forma objetiva y económica, permiten explicar y predecir la calidad sensorial del vino, apoyando así el control de calidad en la producción.

Planteamiento del problema

Depender exclusivamente de catadores humanos para evaluar cada lote de producción limita la rapidez y la escalabilidad del control de calidad en una vinícola. Resulta relevante contar con un método basado en datos que relacione las propiedades fisicoquímicas —obtenidas mediante pruebas de laboratorio estándar y disponibles de forma inmediata— con la calidad final del producto.

Se requiere, por lo tanto, información sobre: (1) qué variables fisicoquímicas están más asociadas con una calidad alta o baja, (2) si es posible estimar



numéricamente la puntuación de calidad a partir de dichas variables, y (3) si existen agrupaciones naturales de vinos con perfiles químicos similares que ayuden a entender mejor la relación entre composición y calidad.

Pregunta principal de análisis

¿En qué medida las características fisicoquímicas de un vino (acidez, azúcar residual, alcohol, sulfatos, entre otras) permiten explicar y predecir su calidad sensorial, y es posible utilizarlas para clasificar los vinos en niveles de calidad sin recurrir a un panel de cata?

Objetivo general

Desarrollar un proceso de análisis de datos que permita modelar la relación entre las propiedades fisicoquímicas del vino verde portugués (tinto y blanco) y su calidad sensorial, mediante técnicas de regresión, clasificación y análisis no supervisado, con el fin de apoyar la toma de decisiones en el control de calidad vitivinícola.

Objetivos específicos

1. Explorar y preparar los datos. Analizar y limpiar los conjuntos winequality-red.csv y winequality-white.csv, identificando valores atípicos, datos faltantes y correlaciones entre variables (Unidad I).
2. Modelar la calidad mediante regresión. Construir y evaluar al menos dos modelos de regresión para predecir la puntuación de calidad (quality), comparando su desempeño con métricas como MAE y RMSE (Unidad II).



3. Clasificar los vinos por nivel de calidad. Construir y evaluar al menos un modelo de clasificación que agrupe los vinos en categorías de calidad baja, media y alta, reportando su exactitud (accuracy) y matriz de confusión (Unidad III).
4. Identificar perfiles fisicoquímicos. Aplicar técnicas de agrupamiento (clustering) y reducción de dimensionalidad (por ejemplo, k-means y PCA) para detectar perfiles de vino con composición química similar (Unidad IV).
5. Comunicar los resultados. Presentar los hallazgos del proyecto mediante un dashboard interactivo que resuma el comportamiento de las variables y el desempeño de los modelos (Unidad V).

Alcance y limitaciones

Alcance

El proyecto abarca el análisis exploratorio, la preparación de datos, la construcción de modelos de regresión y clasificación para predecir y categorizar la calidad del vino, la aplicación de técnicas no supervisadas para encontrar perfiles fisicoquímicos, y la presentación final de resultados mediante un dashboard, trabajando con los dos subconjuntos (tinto y blanco) del dataset Wine Quality.

Limitaciones

El dataset proviene de una sola región (variante "Vinho Verde" de Portugal), por lo que los resultados no necesariamente se generalizan a otros tipos de vino. No incluye variables como marca, precio o variedad de uva. La variable de calidad refleja la evaluación subjetiva de un grupo específico de catadores, y las clases están desbalanceadas: hay muchos más vinos de calidad media que de calidad muy alta o muy baja, lo que puede dificultar la clasificación de estos últimos.



Descripción del dataset

Procedencia

UCI Machine Learning Repository, a partir del trabajo de Cortez, Cerdeira, Almeida, Matos y Reis (2009), realizado en colaboración con la Comissão de Viticultura da Região dos Vinhos Verdes (CVRVV) de Portugal. El dataset está disponible bajo licencia Creative Commons Attribution 4.0.

Tamaño

Se compone de dos archivos: winequality-white.csv, con 4,898 registros, y winequality-red.csv, con 1,599 registros; en conjunto suman 6,497 registros.

Variables

Cada registro contiene 11 variables de entrada, todas numéricas continuas (fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates y alcohol), más 1 variable de salida (quality), de tipo entero, con valores de 0 a 10.

Posibles variables objetivo

La variable quality funciona como objetivo tanto para regresión (predicción de la puntuación exacta) como para clasificación (una vez agrupada en categorías de calidad); este punto se desarrolla con más detalle en la sección 13.

Análisis comparativo: IA, Machine Learning, Data Mining y Big Data

A continuación se comparan los cuatro conceptos en términos de características, beneficios, restricciones, retos, casos de aplicación, y lenguajes y herramientas.

Inteligencia Artificial (IA)



Aspecto	Descripción
Características	Disciplina amplia que busca que las máquinas realicen tareas que requieren razonamiento, aprendizaje, percepción o toma de decisiones, de forma similar a como lo haría una persona.
Beneficios	Automatiza tareas cognitivas complejas, mejora la toma de decisiones y permite sistemas que se adaptan al contexto (visión por computadora, lenguaje natural, planeación).
Restricciones	Requiere grandes volúmenes de datos y capacidad de cómputo; muchos modelos son poco interpretables ("caja negra") y pueden heredar sesgos de los datos.
Retos	Explicabilidad de los modelos, consideraciones éticas y regulatorias, consumo energético y generalización a contextos nuevos.
Casos de aplicación	Asistentes virtuales, vehículos autónomos, diagnóstico médico asistido, sistemas de recomendación.
Lenguajes y herramientas	Python, Java, C++; frameworks como TensorFlow, PyTorch y OpenCV; plataformas como IBM Watson y Azure AI.

Machine Learning (ML)

Aspecto	Descripción
Características	Subcampo de la IA enfocado en algoritmos que aprenden patrones a partir de datos para hacer predicciones o decisiones, sin ser programados explícitamente para cada caso.
Beneficios	Automatiza la construcción de modelos predictivos y mejora conforme recibe más datos; es aplicable a tareas de regresión, clasificación y agrupamiento, como las de este proyecto.
Restricciones	Depende fuertemente de la calidad y cantidad de los datos disponibles; existe riesgo de sobreajuste (overfitting) y requiere una selección adecuada de variables e hiperparámetros.



Retos	Mantenimiento de los modelos ante cambios en los datos (model drift), interpretabilidad de resultados y sesgos presentes en los datos de entrenamiento.
Casos de aplicación	Predicción de calidad de productos (como el caso de este proyecto), detección de fraude, sistemas de recomendación, mantenimiento predictivo.
Lenguajes y herramientas	Python (scikit-learn, pandas, NumPy), R; entornos como Jupyter Notebook y Google Colab.

Data Mining (Minería de Datos)

Aspecto	Descripción
Características	Proceso orientado a descubrir patrones, relaciones y conocimiento útil, no evidente a simple vista, dentro de grandes volúmenes de datos históricos.
Beneficios	Revela relaciones ocultas entre variables, apoya la toma de decisiones estratégicas y combina técnicas estadísticas con algoritmos de aprendizaje automático.
Restricciones	Requiere datos limpios y bien estructurados; los resultados dependen en gran medida de la metodología empleada (por ejemplo, CRISP-DM) y pueden surgir correlaciones espurias.
Retos	Calidad e integración de datos provenientes de distintas fuentes, privacidad de la información e interpretación correcta de los patrones encontrados.
Casos de aplicación	Segmentación de clientes, análisis de canasta de mercado, y control de calidad industrial —como el análisis fisicoquímico del vino de este proyecto.
Lenguajes y herramientas	Python, R, SQL; herramientas como RapidMiner, Orange, Weka y KNIME.



Big Data

Aspecto	Descripción
Características	Se refiere al manejo de volúmenes de datos muy grandes, variados y generados a alta velocidad, descritos comúnmente mediante las "V": volumen, velocidad, variedad, veracidad y valor.
Beneficios	Permite almacenar y procesar información a gran escala, habilita análisis en tiempo real y soporta decisiones basadas en datos masivos.
Restricciones	Requiere infraestructura especializada (clústeres, almacenamiento distribuido), implica un alto costo de implementación y necesita personal especializado.
Retos	Gobernanza y calidad del dato, seguridad y privacidad, escalabilidad de los sistemas e integración con herramientas de análisis.
Casos de aplicación	Análisis de redes sociales, monitoreo de sensores IoT, análisis de registros (logs) de servidores, análisis financiero en tiempo real.
Lenguajes y herramientas	Apache Hadoop, Apache Spark, Hive, Kafka; lenguajes como Scala, Python y SQL.

Dado que el dataset de este proyecto tiene un tamaño moderado (6,497 registros), no se requieren herramientas de Big Data; el proyecto se ubica principalmente en el terreno de Machine Learning y Data Mining, aplicando conceptos generales de IA.



Herramientas propuestas

Aspecto	Descripción
Lenguaje	Python, por su ecosistema maduro para ciencia de datos y la experiencia previa del estudiante trabajando en distintas capas de desarrollo de software.
Bibliotecas	pandas y NumPy para manipulación y limpieza de datos; matplotlib y seaborn para visualización exploratoria; scikit-learn para regresión, clasificación, clustering, PCA y métricas de evaluación.
Entorno de trabajo	Jupyter Notebook / Google Colab, para documentar el análisis de forma reproducible y compartible.
Gestor de base de datos	SQLite para una primera organización local de los datos limpios, como base para el Data Mart que se definirá en la Unidad II.
Control de versiones	Git y GitHub, para versionar el código, los datos procesados y la documentación del proyecto.
Visualización final	Plotly / Power BI, para construir el dashboard interactivo que se entregará en la Unidad V.

Metodología: CRISP-DM

Se adoptará CRISP-DM (Cross Industry Standard Process for Data Mining), la metodología de referencia para proyectos de minería de datos (Chapman et al., 2000), por ser independiente de la industria y de la herramienta utilizada, y por su amplia adopción en proyectos similares. Sus seis fases son:

- 1. Comprensión del negocio:** Definir los objetivos y requerimientos del proyecto desde la perspectiva del problema a resolver, traducéndose en un objetivo de minería de datos.
- 2. Comprensión de los datos:** Recolectar, describir y explorar los datos iniciales para evaluar su calidad y detectar primeros patrones.



- 3. Preparación de los datos:** Limpiar, transformar, integrar y seleccionar las variables que conformarán el conjunto final de datos de modelado.
- 4. Modelado:** Seleccionar y aplicar técnicas de modelado (regresión, clasificación, clustering), calibrando sus parámetros.
- 5. Evaluación:** Valorar si los modelos obtenidos cumplen los objetivos planteados antes de considerar su uso.
- 6. Despliegue:** Organizar y presentar el conocimiento obtenido de forma que pueda ser utilizado, por ejemplo, mediante un reporte o dashboard.

Aplicación de la metodología al caso

Aspecto	Descripción
Comprensión del negocio	Unidad I (este documento): definición del problema, preguntas, objetivos, alcance y descripción inicial del dataset.
Comprensión de los datos	Unidad II (revisión 9 de octubre): exploración inicial, diccionario de datos, detección de valores atípicos y faltantes, análisis de correlación.
Preparación de los datos	Unidad II (entrega 16 de octubre): limpieza, escalado de variables, creación de las categorías de calidad y propuesta de Data Warehouse / Data Mart.
Modelado	Unidad III (30 de octubre): modelos de regresión para predecir quality y modelos de clasificación para las categorías baja/media/alta.
Evaluación	Unidades III y IV: métricas de regresión (MAE, RMSE), de clasificación (accuracy, matriz de confusión) y de clustering (por ejemplo, silhouette score).
Despliegue	Unidad V (20 de noviembre): dashboard interactivo, storytelling de los hallazgos y repositorio final documentado.



Definición preliminar del análisis supervisado

Posible variable objetivo para regresión

quality (calidad del vino): puntuación numérica continua, de 0 a 10, asignada mediante cata sensorial. El modelo de regresión buscará predecir este valor exacto a partir de las 11 variables fisicoquímicas.

Posible variable objetivo para clasificación

También quality, pero discretizada en tres categorías, de acuerdo con el siguiente criterio:

- Baja: quality menor o igual a 5.
- Media: quality igual a 6.
- Alta: quality mayor o igual a 7.

Este criterio se eligió porque la mayoría de los vinos del dataset se concentra en las calificaciones 5 y 6, por lo que agrupar alrededor de ese punto medio permite obtener tres clases con un volumen razonable de datos en cada una, en lugar de clases extremadamente desbalanceadas. El modelo de clasificación asignará cada vino a una de estas tres clases a partir de sus propiedades fisicoquímicas.

Resultados esperados

- Identificar qué variables fisicoquímicas influyen más en la calidad del vino.
- Obtener un modelo de regresión con un error (RMSE) aceptable para estimar la puntuación de calidad.
- Obtener un modelo de clasificación capaz de distinguir razonablemente bien entre vinos de calidad baja, media y alta.



- Descubrir, mediante clustering, posibles perfiles fisicoquímicos de vino que no se correspondan directamente con la calidad declarada.
- Comunicar estos hallazgos de forma clara a usuarios no técnicos (por ejemplo, un enólogo o responsable de control de calidad) mediante un dashboard.

Cronograma preliminar

Con base en el calendario oficial del recursamiento (23 de septiembre al 20 de noviembre de 2026):

Fecha	Etapas / evidencia	Carácter
23 sept. 2026	Publicación del paquete de recursamiento	Inicio
25 sept. 2026	Actividad 0 — Inicio y registro	Seguimiento obligatorio
2 oct. 2026	Unidad I — Planeación del proyecto (este documento)	Evaluable 20%
9 oct. 2026	Revisión Unidad II	Revisión obligatoria
16 oct. 2026	Unidad II — Preparación de datos	Evaluable 15%
23 oct. 2026	Revisión Unidad III	Revisión obligatoria
30 oct. 2026	Unidad III — Análisis supervisado	Evaluable 25%
6 nov. 2026	Revisión Unidad IV	Revisión obligatoria
13 nov. 2026	Unidad IV — Análisis no supervisado	Evaluable 25%
17 nov. 2026	Revisión Unidad V	Revisión obligatoria
20 nov. 2026	Unidad V y cierre del recursamiento	Evaluable 15% / cierre



Referencias (formato APA)

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc. Recuperado de [\[PDF\] CRISP-DM 1.0: Step-by-step data mining guide | Semantic Scholar](#)

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, 47(4), 547–553. Recuperado de [Modeling wine preferences by data mining from physicochemical properties](#)

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Wine quality [Conjunto de datos]. UCI Machine Learning Repository. [Wine Quality - UCI Machine Learning Repository](#)

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. Recuperado de [Scikit-learn: Machine Learning in Python](#)